ĐỒ ÁN NGHIÊN CỨU / RESEARCH PROJECT

ĐẶC TẢ ĐỀ CƯƠNG NGHIÊN CỨU VÀ XÂY DỰNG HỆ THỐNG PHÂN LOẠI VĂN BẢN TIẾNG VIỆT ĐA NHÃN THEO CHỦ ĐỀ

Vietnamese Multi-label Text Topic Classification

Phiên bản 2.0 • 24/10/2026

Nguồn dữ liệu nghiên cứu chính: VTSNLP/vietnamese_curated_dataset

Repository đề xuất: vietnamese-multilabel-topic-classification

TÀI LIỆU ĐỀ XUẤT PHẠM VI • THIẾT KẾ NGHIÊN CỨU • KẾ HOẠCH TRIỂN KHAI

THÔNG TIN TÀI LIỆU

Hạng mục	Nội dung
Tên đề tài	Nghiên cứu và xây dựng hệ thống phân loại văn bản tiếng Việt đa nhãn theo chủ đề
Tên tiếng Anh	Vietnamese Multi-label Text Topic Classification
Định hướng	Text-only; multi-label classification; nghiên cứu có kiểm chứng
Nguồn dữ liệu	VTSNLP Vietnamese Curated Dataset; tập nhãn đa nhãn xây dựng riêng
Người thực hiện / GVHD	Điền theo thông tin sinh viên, nhóm và cơ sở đào tạo
Thời gian đề xuất	16 tuần (điều chỉnh theo số người gán nhãn và tài nguyên GPU)
Phiên bản	2.0 • 24/10/2026 • thay thế đề cương kiểm duyệt đa phương thức v1.0

Tóm tắt đề xuất

Đồ án xây dựng hệ thống tự động gán đồng thời nhiều chủ đề cho một văn bản tiếng Việt. Trọng tâm nghiên cứu là thiết kế taxonomy, tạo tập dữ liệu đa nhãn có chất lượng, so sánh mô hình baseline với PhoBERT và phát triển API/demo suy luận. Bộ VTSNLP đóng vai trò nguồn văn bản và thông tin lấy mẫu; nhãn domain gốc KHÔNG được coi là nhãn multi-label chuẩn.

GIỚI HẠN PHẠM VI

Không xử lý ảnh, video, audio, OCR/ASR; không thực hiện kiểm duyệt nội dung, dự báo vi phạm chính sách hoặc ra quyết định gỡ bài. Đây là bài toán phân loại chủ đề, không phải moderation.

Tóm tắt mục tiêu nghiệm thu

- Taxonomy 8-10 chủ đề được định nghĩa rõ, cho phép một văn bản có 0, 1 hoặc nhiều nhãn.
- Pipeline lấy mẫu, chuẩn hóa, kiểm tra trùng lặp, gán nhãn và tách train/validation/test có thể tái lập.
- Ít nhất một baseline truyền thống và một mô hình Transformer, kèm báo cáo đánh giá đa nhãn trên tập test độc lập.
- API và giao diện demo nhận văn bản tiếng Việt, trả danh sách chủ đề cùng score và ngưỡng dự đoán.

Cấu trúc tài liệu

01 Bối cảnh & bài toán • 02 Phạm vi & mục tiêu • 03 Taxonomy chủ đề • 04 Dữ liệu • 05 Gán nhãn • 06 Kiến trúc • 07 Mô hình • 08 Đánh giá • 09 Yêu cầu • 10 Lộ trình • 11 Rủi ro & nghiệm thu • 12 Tài liệu tham khảo • Phụ lục

01. TỔNG QUAN VÀ PHÁT BIỂU BÀI TOÁN

1.1. Bối cảnh

Các tài liệu tiếng Việt có thể đồng thời đề cập đến nhiều lĩnh vực. Ví dụ bài viết về chính sách hỗ trợ doanh nghiệp nghiên cứu AI có thể thuộc Công nghệ, Kinh tế và Chính trị/Chính sách công. Phân loại một nhãn duy

nhất làm mất thông tin chủ đề chồng lấn; multi-label classification cho phép biểu diễn mức liên quan của nhiều chủ đề trên cùng tài liệu.

1.2. Phát biểu bài toán

Cho văn bản tiếng Việt x và danh sách chủ đề C = {c1, ..., cK}, xây dựng mô hình f(x) = [p1, ..., pK] với pj trong [0,1]. Sau bước hiệu chỉnh ngưỡng tj theo từng nhãn, hệ thống trả tập nhãn dự đoán Ŷ(x) = {cj | pj ≥ tj}. Không bắt buộc có ít nhất một nhãn nếu văn bản ngoài phạm vi taxonomy.

1.3. Câu hỏi nghiên cứu

1. RQ1: Mô hình PhoBERT cải thiện Micro-F1/Macro-F1 và PR-AUC như thế nào so với TF-IDF + Logistic Regression One-vs-Rest trên cùng tập dữ liệu có nhãn đã kiểm chứng?
2. RQ2: Hiệu chỉnh ngưỡng riêng theo nhãn trên validation có cải thiện chất lượng so với ngưỡng cố định 0,5 không?
3. RQ3: Cách xử lý văn bản dài (cắt đoạn đầu so với chia đoạn và tổng hợp) ảnh hưởng thế nào đến khả năng phát hiện chủ đề chồng lấn?
4. RQ4 (mở rộng): Nhãn gợi ý bán tự động có giúp giảm thời gian gán nhãn nhưng vẫn giữ chất lượng so với gán nhãn thuần thủ công không?

1.4. Đóng góp kỳ vọng

- Quy trình chuyển một kho văn bản đơn nhãn/nhãn miền thành bài toán multi-label có căn cứ.
- Bộ hướng dẫn gán nhãn, tập mẫu kiểm chứng, baseline và thí nghiệm tái lập.
- Phân tích lỗi theo nhãn, số nhãn mỗi mẫu, nguồn và độ dài văn bản; demo minh họa ứng dụng.

02. PHẠM VI, GIẢ ĐỊNH VÀ GIỚI HẠN

Hạng mục	Trong MVP	Ngoài MVP
Đầu vào	Một văn bản tiếng Việt, có thể dài và nhiều chủ đề	Ảnh, video, âm thanh, OCR/ASR
Đầu ra	0-n chủ đề, xác suất/score và ngưỡng	Quyết định moderation hoặc xác thực tin giả
Hệ thống	Pipeline dữ liệu, train/eval, API và demo	Thu thập web diện rộng / nền tảng quy mô lớn
Thực nghiệm	Baseline + PhoBERT, thresholds, xử lý văn bản dài	Pretraining LLM mới từ đầu
Phạm vi ngôn ngữ	Tiếng Việt chuẩn; khảo sát lỗi tiếng lóng/pha Anh	Cam kết hiệu quả mọi ngôn ngữ

Quy tắc thiết kế: ưu tiên chất lượng nhãn và dữ liệu đánh giá độc lập hơn số lượng tài liệu huấn luyện. Mọi chỉ tiêu về số mẫu và tiến độ bên dưới là mục tiêu đề xuất, chưa phải kết quả đã hoàn thành.

03. TAXONOMY CHỦ ĐỀ ĐỀ XUẤT

3.1. Danh mục nhãn v0.1 - cần xác nhận qua pilot

Mã	Tên nhãn	Giới hạn định nghĩa / ranh giới
T01	Công nghệ	Phần mềm, AI, thiết bị, chuyển đổi số; phân biệt với nghiên cứu khoa học thuần túy.
T02	Kinh tế - Tài chính	Thị trường, doanh nghiệp, ngân hàng, đầu tư, kinh doanh.
T03	Chính trị - Chính sách công	Chính phủ, quản trị công, chính sách, ngoại giao, bầu cử.
T04	Giáo dục	Đào tạo, trường học, giáo viên, học tập, chương trình giáo dục.
T05	Y tế - Sức khỏe	Chăm sóc sức khỏe, y khoa, bệnh tật, hệ thống y tế.
T06	Khoa học	Nghiên cứu, khám phá, phương pháp khoa học; có thể đồng nhãn Công nghệ.
T07	Thể thao	Thi đấu, vận động viên, giải đấu, hoạt động thể thao.
T08	Văn hóa - Giải trí	Nghệ thuật, sách, âm nhạc, điện ảnh, lễ hội, nội dung giải trí.
T09	Pháp luật	Quy định pháp lý, tố tụng, tòa án, trách nhiệm pháp lý.
T10	Môi trường	Khí hậu, ô nhiễm, tài nguyên, bảo tồn và phát triển bền vững.

LƯU Ý VỀ TAXONOMY

Đây là bộ nhãn CHÚNG TA đề xuất cho đồ án, không phải 10 nhãn có sẵn trong VTSNLP. Có thể giảm xuống 8 nhãn khi số mẫu dương cho một số nhãn quá ít; thay đổi phải được version và cập nhật toàn bộ guideline.

3.2. Quy tắc đa nhãn

- Gán tất cả chủ đề có nội dung đáng kể; một nhắc đến thoáng qua chưa đủ để gán nhãn.
- Các cặp nhãn có thể đồng xuất hiện, ví dụ T01+T02 hoặc T03+T09; không ép chọn một nhãn chính.
- Văn bản ngoài taxonomy được đánh dấu no_in_scope_topic, không tạo nhãn "Khác" giả làm một chủ đề cạnh tranh.
- Với mỗi nhãn trong annotation, phân biệt positive, negative đã kiểm tra và unknown/chưa đánh giá; unknown không tự động đổi thành 0.

3.3. Ví dụ minh họa

Văn bản rút gọn	Nhãn đề xuất (minh họa)
"Chính phủ hỗ trợ doanh nghiệp ứng dụng AI trong ngân hàng."	T01 Công nghệ + T02 Kinh tế - Tài chính + T03 Chính trị - Chính sách công

"Trường đại học công bố nghiên cứu mới về xử lý ô nhiễm nước."	T04 Giáo dục + T06 Khoa học + T10 Môi trường
"Đội tuyển bóng đá thắng trận giao hữu quốc tế."	T07 Thể thao

04. DỮ LIỆU VÀ CHIẾN LƯỢC LẤY MẪU

4.1. Vai trò và giới hạn của VTSNLP

Dataset VTSNLP/vietnamese_curated_dataset do Viettel Solutions phát triển, tổng hợp văn bản tiếng Việt từ C4, OSCAR, Wikipedia và dữ liệu tin tức; đã được xử lý curation. Dataset card thể hiện 12.169.131 bản ghi, một split train và ba trường text, id, domain. Trường domain là một chuỗi duy nhất; trong giao diện dữ liệu có 25 giá trị domain. Thông tin này KHÔNG chứng minh tài liệu có đầy đủ các nhãn chủ đề liên quan.

Trường gốc	Sử dụng trong đồ án	Lưu ý
id	Khóa tham chiếu và đối soát nguồn	Kiểm tra unique ID; không giả định không trùng văn bản.
text	Nội dung đầu vào để sampling, annotation, model	Văn bản có thể rất dài, nhiều chủ đề hoặc chứa nhiễu.
domain	Phân tầng khảo sát/đối chiếu heuristic	Không dùng làm ground truth multi-label; News là miền/loại nguồn, không nhất thiết một topic.

Tại thời điểm soạn đề cương, thông tin giấy phép tổng thể không được nêu rõ trong phần metadata/card đã tham khảo. Trước khi sao chép, chia sẻ hoặc công bố dữ liệu đã trích, cần kiểm tra điều kiện cấp phép của dataset và các nguồn thành phần; trường hợp chưa rõ, chỉ phát hành mã nguồn, ID/metadata được phép và hướng dẫn tái tạo.

4.2. Kế hoạch thu nhận và lấy mẫu

5. Lấy mẫu streaming 2.000-5.000 bản ghi phục vụ EDA, kiểm tra phân phối domain, số token, nguồn trùng lặp và độ dài; đây KHÔNG phải dữ liệu có nhãn multi-label.
6. Xây chiến lược chọn mẫu hỗn hợp: ngẫu nhiên theo domain, truy hồi theo từ khóa chủ đề, oversample tài liệu có khả năng chồng lấn và các ca khó; lưu tỉ lệ lấy mẫu.
7. Khóa danh sách candidate IDs, seed và revision dữ liệu; hạn chế phụ thuộc vào thứ tự stream và buffer shuffle (không bảo đảm ngẫu nhiên đều tuyệt đối).
8. Khảo sát license và chất lượng, loại nội dung rỗng/hỏng, bản sao/near-duplicate, và ghi lý do loại bỏ trước annotation.

4.3. Quy mô mục tiêu (điều chỉnh theo nhân lực)

Tập	Mục tiêu đề xuất	Chú thích
EDA / lấy mẫu ứng viên	2.000-5.000 bản ghi	Dùng nghiên cứu dữ liệu; chưa phải nhãn đúng.
Annotation pilot	200-300 văn bản	Hai người gán độc lập nếu có thể; hiệu chỉnh guideline.
Dataset multi-label	3.000-5.000 văn bản	Bao gồm cả train, validation, test; là mục tiêu, không cam kết.

Validation/Test	Mỗi tập khoảng 10-15%	Có xác minh nhãn và khóa trước thí nghiệm chính.

05. THIẾT KẾ GÁN NHÃN VÀ BẢO ĐẢM CHẤT LƯỢNG

5.1. Quy trình annotation

9. Viết guideline: định nghĩa tích cực/tiêu cực, ví dụ biên, trường hợp đồng xuất hiện và quy ước tài liệu thiếu ngữ cảnh.
10. Pilot 200-300 mẫu: ít nhất hai người gán độc lập trên tập kiểm thử guideline khi có nguồn lực; phân tích bất đồng và cập nhật taxonomy v0.2.
11. Tạo pre-label/gợi ý bằng từ khóa hoặc mô hình zero-shot nếu cần tiết kiệm thời gian; chỉ xem là gợi ý, KHÔNG là ground truth.
12. Gán nhãn chính: xác nhận tất cả nhãn dương và nhãn âm trong scope; lưu trạng thái unknown nếu người gán chưa đọc đủ hoặc không chắc.
13. Kiểm soát chất lượng: double-label toàn bộ validation/test ở mức khả thi; chấm chéo ít nhất một phần train và phân xử bất đồng bằng guideline.

5.2. Schema dữ liệu chuẩn

Trường	Ví dụ / ràng buộc
sample_id / source_id	"vtsnlp_00042" / id VTSNLP
text / original_domain	Nội dung đã được xử lý an toàn / "News"
taxonomy_version	"topic-v0.2"
positive_labels	["T01", "T02"]
negative_labels	["T03", "T04", ...] - chỉ nhãn được đánh giá rõ
unknown_labels	[] hoặc danh sách nhãn chưa xác định
annotator / adjudication	Mã annotator ẩn danh, thời gian, trạng thái phân xử
split / group_id / text_hash	"train" / nhóm nguồn-trùng lặp / hash

5.3. Tiêu chí chất lượng

- Báo cáo tần suất nhãn, nhãn hiếm, label cardinality (số nhãn dương trung bình/mẫu), label density và tỷ lệ không thuộc taxonomy.
- Cohen’s kappa theo từng nhãn khi thích hợp, mức độ thống nhất dương, tỷ lệ bất đồng và ví dụ cần sửa guideline; không dùng một hệ số duy nhất để che nhãn hiếm.
- Đối với train có unknown_labels: chỉ huấn luyện trên các mục tiêu quan sát được với masked loss, hoặc lọc ví dụ thiếu xác nhận; baseline OVR yêu cầu ma trận nhãn đầy đủ.

NGUYÊN TẮC KHÔNG RÒ RỈ

Chia train/validation/test theo nhóm tài liệu gốc và near-duplicate, sau đó cố định split. Không dùng validation/test để sinh pseudo-label cho train, chọn mẫu gán nhãn theo lỗi của test hoặc điều chỉnh threshold trên test.

06. KIẾN TRÚC HỆ THỐNG VÀ PIPELINE

6.1. Luồng dữ liệu end-to-end

01 / DATA INGESTION	Hugging Face streaming → bản ghi nguồn → manifest + revision/seed
02 / DATA QUALITY	Chuẩn Unicode, kiểm tra độ dài, nhận diện trùng lặp, EDA
03 / TOPIC ANNOTATION	Taxonomy + guideline → nhãn đa nhãn đã xác minh → nhóm split
04 / TRAINING	TF-IDF + OVR → PhoBERT multi-label → lưu checkpoints và config
05 / EVALUATION	Validation thresholds → test khóa → lỗi theo nhãn và theo độ dài
06 / SERVING	FastAPI + demo → probabilities → thresholds → topic labels

6.2. Bố cục repository khuyến nghị

Thư mục	Chức năng
configs/	Taxonomy YAML, cấu hình mô hình, thresholds, dataset revision.
src/data/	Tải/stream, sampling, preprocessing, dedup, split.
src/annotation/	Schema, validate nhãn, QC và công cụ hỗ trợ.
src/models/	Baseline TF-IDF/OVR, PhoBERT multi-label, chunk aggregation.
src/evaluation/	Metric, calibration, error analysis, compare runs.
src/api/ và demo/	FastAPI và giao diện thử nghiệm.
tests/, reports/, docs/	Unit/integration tests, metrics, data card/model card, guideline.

Quản lý môi trường qua pyproject.toml và uv.lock; seed/config/model version ghi lại trong từng run. Raw dataset không được commit vào GitHub. Có thể lưu data artifacts trên Google Drive hoặc storage tương đương theo phạm vi quyền sử dụng, không bắt buộc triển khai data lake quy mô lớn.

07. THIẾT KẾ MÔ HÌNH VÀ THỰC NGHIỆM

7.1. Phương án mô hình

Mã	Phương án	Mục đích
E0	Majority/frequency baseline theo nhãn	Tham chiếu sàn để phát hiện nhãn lệch.
E1	TF-IDF + Logistic Regression, One-vs-Rest	Baseline chính, chi phí thấp, dễ giải thích.
E2	PhoBERT-base + K sigmoid outputs + BCEWithLogitsLoss	Khai thác biểu diễn ngữ cảnh tiếng Việt.
E3	E2 + threshold riêng từng nhãn	Kiểm định lợi ích threshold tuning.
E4	E2 + chunking/aggregation trên tài liệu dài	Đánh giá ảnh hưởng độ dài và cắt ngữ cảnh.
E5 (tùy chọn)	Classifier chains / weak-label hỗ trợ train	Kiểm định phụ thuộc giữa nhãn hoặc dữ liệu yếu.

7.2. Các lựa chọn kỹ thuật quan trọng

- Multi-label head dùng sigmoid độc lập theo nhãn và binary cross-entropy, không dùng softmax nhiều lớp.
- PhoBERT có giới hạn ngữ cảnh; cần benchmark truncation so với chia đoạn/tổng hợp (max/mean/noisy-or) theo tài nguyên thực.
- Áp dụng tokenization/word segmentation phù hợp với checkpoint được chọn, ghi chính xác version.
- Thử class weights/positive weights chỉ trên train và kiểm soát trường hợp lớp có quá ít mẫu dương.
- Tối ưu threshold trên validation (ngưỡng chung 0,5 vs. per-label); nếu dữ liệu validation quá ít, ưu tiên quy tắc ổn định và báo cáo bất định.

7.3. Kiểm soát thí nghiệm

Cố định split, seed, tập nhãn, max length và budget tính toán trong các so sánh công bằng. Lưu git commit, config, số mẫu từng nhãn, checkpoint, thời gian train và giới hạn thiết bị. Không so sánh trực tiếp các run dùng phiên bản taxonomy hoặc tập test khác nhau.

08. ĐÁNH GIÁ, PHÂN TÍCH LỖI VÀ KIỂM THỬ

8.1. Thước đo bắt buộc

Nhóm	Thước đo	Ý nghĩa
Chính	Micro-F1, Macro-F1	Tổng quát và độ cân bằng giữa các nhãn.
Theo nhãn	Precision / Recall / F1 từng nhãn	Xác định lớp khó, lớp hiếm và nhầm lẫn.
Theo xác suất	PR-AUC theo nhãn; micro/macro khi khả thi	Phù hợp phân phối nhãn mất cân bằng.
Theo mẫu	Samples-F1, Jaccard; Hamming loss	Khớp tập nhãn của mỗi văn bản.
Vận hành	p50/p95 inference latency, RAM/VRAM	Chi phí suy luận theo cấu hình phần cứng.
Chất lượng dữ liệu	Agreement, tỷ lệ unknown, multi-label rate	Chất lượng ground truth và khả năng nghiên cứu.

8.2. Thiết kế đánh giá

- Tất cả tuning hyperparameter và threshold diễn ra trên train/validation; test chỉ dùng để công bố kết quả cuối.
- Phân tích theo độ dài văn bản, domain gốc, số nhãn dương, nhãn hiếm, các cặp nhãn chồng lấn và lỗi do nhiễu.
- Báo cáo ma trận TP/FP/FN/TN cho từng nhãn; không dùng một confusion matrix đa lớp để đại diện toàn bộ bài toán multi-label.
- Phân tích ít nhất 30 ca lỗi tiêu biểu, mô tả nguyên nhân: bỏ sót nhãn phụ, nhãn gần nghĩa, văn bản quá dài, annotation ambiguous.
- Nếu một nhãn thiếu đủ mẫu dương trong test để ước lượng ổn định, công bố kết quả thăm dò và khoảng bất định, không khẳng định độ chính xác tổng quát.

8.3. Acceptance tests mẫu

ID	Đầu vào / yêu cầu	Kỳ vọng
AT-01	Văn bản có T01+T02+T03	API có khả năng trả nhiều chủ đề độc lập.
AT-02	Văn bản chỉ về bóng đá	Có thể dự đoán T07, không ép thêm nhãn khác.
AT-03	Văn bản ngoài toàn bộ 10 chủ đề	Cho phép danh sách nhãn rỗng.
AT-04	Chuỗi rỗng hoặc quá dài	Validation rõ ràng; cơ chế chunk/truncate được ghi nhận.
AT-05	Văn bản Unicode/teencode nhiễu	Không lỗi xử lý, kết quả được tính vào phân tích robustness.

09. YÊU CẦU PHẦN MỀM VÀ HỢP ĐỒNG API

9.1. Functional requirements

Mã	Ưu tiên	Yêu cầu
FR-01	M	Nhận và validate văn bản Unicode tiếng Việt.
FR-02	M	Áp dụng preprocessing cùng phiên bản với lúc train.
FR-03	M	Trả K score và tập nhãn vượt ngưỡng kèm taxonomy/model version.
FR-04	M	Hỗ trợ 0, 1 hoặc nhiều nhãn (không ép top-1).
FR-05	M	Chạy đánh giá và xuất metrics/reports theo nhãn, theo tập.
FR-06	M	Demo thử nghiệm nhập văn bản và hiển thị score.
FR-07	S	Hỗ trợ xử lý văn bản dài theo chunk/aggregation.

FR-08	S	Log ID ẩn danh, latency, model version; không log văn bản nhạy cảm mặc định.
FR-09	C	Batch prediction và chức năng người dùng sửa/gợi ý nhãn.

9.2. Non-functional requirements

- Tái lập: lưu seed, split, taxonomy, dataset revision, requirements và version của preprocessing.
- An toàn dữ liệu: áp dụng điều kiện license, hạn chế log nội dung, tránh phát tán lại văn bản khi chưa rõ quyền.
- Khả năng kiểm chứng: kết quả test, báo cáo lỗi, cấu hình phần cứng và phiên bản mô hình phải truy vết được.
- Hiệu năng: đo latency p50/p95 trên máy test; không đặt SLA cứng trước khi biết hạ tầng.

9.3. API MVP

Endpoint	Request	Response chính
POST /v1/topics/predict	{ "text": "..." }	document_id, labels[{code, score, threshold}], all_scores, taxonomy_version, model_version
POST /v1/topics/batch (S)	Danh sách văn bản	Danh sách kết quả + lỗi theo item
GET /health	Không cần body	status, model_loaded, version

Schema trên là thiết kế mục tiêu, chưa phải API đã tồn tại. Không hiển thị score như "độ chắc chắn tuyệt đối" nếu chưa đánh giá calibration.

10. KẾ HOẠCH TRIỂN KHAI 16 TUẦN

Giai đoạn	Tuần	Đầu việc chính	Sản phẩm
P1 - Khảo sát	1-2	Kiểm tra VTSNLP, giấy phép, streaming, EDA, xác định nhãn sơ bộ.	Data audit v1, taxonomy v0.1
P2 - Annotation pilot	3-4	Guideline, mẫu cân bằng, pilot 200-300 mẫu, adjudication, sửa taxonomy.	Guideline v1, QC report
P3 - Dataset	5-7	Mở rộng 3k-5k mẫu nếu khả thi, QC, dedup, group split, data card.	Labeled dataset v1, split manifest
P4 - Baseline	8-9	TF-IDF+OVR, kiểm thử dữ liệu, đánh giá validation.	Metrics E0/E1, pipeline tái lập
P5 - Transformer	10-12	Fine-tune PhoBERT, thresholds, experiment tài liệu dài.	E2-E4 + ablation
P6 - API & Demo	13-14	FastAPI, demo text-only, integration/unit tests.	Ứng dụng demo và test report
P7 - Kết luận	15-16	Test khóa, phân tích lỗi, tài liệu/báo cáo và trình bày.	Repo, model card, slides, báo cáo

10.1. Cổng quyết định theo tiến độ

- Gate A (hết tuần 2): Chốt quyền sử dụng, kiểm tra nguồn dữ liệu và có mẫu EDA đủ đa dạng.
- Gate B (hết tuần 4): Guideline hoạt động; mỗi nhãn có định nghĩa tách biệt và kế hoạch lấy thêm positives.
- Gate C (hết tuần 7): Có tập test xác minh độc lập và đủ nhãn dương để đánh giá; nếu chưa đủ, giảm số nhãn hoặc mô tả exploratory.
- Gate D (hết tuần 12): Chạy được baseline và ít nhất một Transformer trong cùng điều kiện kiểm chứng.
- Gate E (hết tuần 16): Có demo, báo cáo metric test và artifacts tái lập.

10.2. Kế hoạch dự phòng

Nếu thiếu annotator/GPU, giảm taxonomy về 6-8 nhãn có đủ dữ liệu, giữ test đáng tin cậy, huấn luyện TF-IDF+OVR trước, dùng PhoBERT-base với batch nhỏ/frozen embeddings nếu cần. Không thay bài toán multi-label thành single-label mà vẫn giữ tên đề tài.

11. RỦI RO, SẢN PHẨM BÀN GIAO VÀ NGHIỆM THU

11.1. Rủi ro và giảm thiểu

Rủi ro	Tác động	Biện pháp
Dataset không có nhãn đa nhãn	Không thể train/eval trực tiếp	Tạo pilot, annotation rõ, kiểm chứng test.
License/nguồn chưa rõ	Không thể công khai raw data	Audit điều kiện sử dụng; chỉ phát hành artifacts được phép.
Nhãn hiếm / thiếu chồng lấn	Macro-F1 biến động, thiếu multi-label signal	Chủ động lấy mẫu khó, giảm taxonomy, báo cáo giới hạn.
Nhãn tự sinh sai	Model học sai, số liệu ảo	Tách weak label; không dùng làm test gold.
Near-duplicate leakage	Test quá lạc quan	Hash, near-dup groups và group-aware split.
Thiếu annotator / GPU	Không đạt scope đã đặt	Thực hiện gate và phương án dự phòng sớm.
Văn bản dài	Truncation bỏ nhãn phụ	Chunking ablation, phân tích theo độ dài.

11.2. Deliverables

Mã	Sản phẩm	Tiêu chí xác nhận
D01	Taxonomy + annotation guideline	Định nghĩa, ví dụ positive/negative, version và quy tắc overlap.
D02	Dataset manifest + QC / data card	Nguồn, license, nhãn kiểm chứng, split không rò rỉ.
D03	Baseline + Transformer checkpoints	Có code/config và tập kiểm thử tái lập.
D04	Báo cáo evaluation	Per-label + micro/macro F1, thresholds, error analysis và limitations.
D05	API + text demo	Predict nhiều nhãn và trả score trên văn bản người dùng nhập.

D06	Repo + báo cáo đồ án	README, test, sơ đồ, ethics/license, hướng dẫn chạy.

TIÊU CHÍ THÀNH CÔNG THỰC TẾ

Đồ án đạt mục tiêu khi chứng minh được quy trình gán nhãn đa nhãn có chất lượng, mô hình chạy đúng bài toán, thí nghiệm được so sánh công bằng trên tập test độc lập và có demo hoạt động. Không cam kết một ngưỡng F1 cố định khi chưa kiểm chứng phân phối nhãn.

12. TÀI LIỆU THAM KHẢO

[1] VTSNLP / Viettel Solutions. Vietnamese Curated Dataset (dataset card). https://huggingface.co/datasets/VTSNLP/vietnamese_curated_dataset

[2] VTSNLP dataset README. Schema, split, sources and curation. https://huggingface.co/datasets/VTSNLP/vietnamese_curated_dataset/blob/main/README.md

[3] Nguyen, D. Q., & Nguyen, A. T. (2020). PhoBERT: Pre-trained language models for Vietnamese. Findings of EMNLP 2020. https://aclanthology.org/2020.findings-emnlp.92/

[4] scikit-learn. Multiclass and multioutput algorithms: OneVsRestClassifier, multilabel classification. https://scikit-learn.org/stable/modules/multiclass.html

[5] Sechidis, K., Tsoumakas, G., & Vlahavas, I. (2011). On the Stratification of Multi-label Data. ECML PKDD. (tham khảo chia tập đa nhãn)

[6] Hugging Face Transformers. Sequence classification & multi-label classification documentation. https://huggingface.co/docs/transformers/

Lưu ý nguồn

Các link trong tài liệu cần được kiểm tra lại ngày truy cập trước khi nộp bản chính thức. Các quy mô dữ liệu, mục tiêu annotation và taxonomy do đề cương đề xuất phải được phân biệt rõ với thông số có sẵn từ dataset card.

PHỤ LỤC A. MẪU ĐẦU RA API MINH HỌA

VÍ DỤ GIẢ LẬP - KHÔNG PHẢI KẾT QUẢ MÔ HÌNH ĐÃ HUẤN LUYỆN

Input: “Chính phủ hỗ trợ doanh nghiệp phát triển công nghệ AI phục vụ lĩnh vực tài chính.”

```
{
  "document_id":"demo_001",
  "taxonomy_version":"topic-v0.2",
  "labels":[
    {"code":"T01","score":0.93,"threshold":0.50},
    {"code":"T02","score":0.82,"threshold":0.55},
    {"code":"T03","score":0.73,"threshold":0.60}
  ]
}
```