ĐỒ ÁN NGHIÊN CỨU / RESEARCH PROJECT

ĐẶC TẢ HỆ THỐNG KIỂM DUYỆT NỘI DUNG ĐA PHƯƠNG THỨC TIẾNG VIỆT

Vietnamese Multimodal Content Moderation
Using a Unified Community Safety Taxonomy

Repository vietnamese-multimodal-moderation

Định hướng: Text • Image • Video • Audio trong video

ĐỀ CƯƠNG / SOFTWARE REQUIREMENTS & RESEARCH SPECIFICATION

BẢN 1.0 • 23.10.2026

THÔNG TIN TÀI LIỆU

Bản đặc tả yêu cầu và kế hoạch nghiên cứu, dùng làm cơ sở thống nhất phạm vi, triển khai hệ thống và đánh giá kết quả đồ án.

Hạng mục	Thông tin
Tên đề tài	Xây dựng hệ thống hỗ trợ kiểm duyệt nội dung đa phương thức tiếng Việt dựa trên bộ Tiêu chuẩn cộng đồng thống nhất
Tên dự án / repository	**vietnamese-multimodal-moderation**
Phiên bản / ngày	1.0 • 23/10/2026
Đối tượng	Bài đăng, bình luận, hình ảnh, meme, video ngắn và lời nói trong video
Người thực hiện / GV hướng dẫn	Điền theo thông tin của sinh viên, nhóm và cơ sở đào tạo
Loại tài liệu	Đặc tả phạm vi + SRS + thiết kế nghiên cứu/đánh giá (bản đề xuất)

QUY ƯỚC ĐỌC TÀI LIỆU

Các chỉ tiêu số lượng dữ liệu, thời gian triển khai và ngưỡng đánh giá là **mục tiêu đề xuất** để nghiệm thu; cần hiệu chỉnh theo thời gian, thiết bị và dữ liệu thực có. Bộ nhãn MCST là thiết kế phục vụ nghiên cứu, không được trình bày như chính sách chính thức của Meta hay TikTok.

TÓM TẮT PHẠM VI VÀ KẾT QUẢ KỲ VỌNG

Khía cạnh	Định hướng đã chọn
Bộ quy tắc tham khảo	Meta (độ bao phủ) + TikTok (mức xử lý); MCST v1.0 độc lập.
Phương thức	Văn bản, hình ảnh có OCR, video có khung hình và ASR tiếng Việt.
Độ rộng đề tài	16 nhóm cấp 1; triển khai MVP với 8 nhãn ưu tiên theo dữ liệu thực có.
Mô hình	Baseline đơn phương thức late fusion phân tích ngữ cảnh và Policy Engine.
Đánh giá	Macro-F1, Recall/Precision, false positives, agreement, ablation và giải thích lỗi.
Lộ trình tham chiếu	16 tuần, từ khảo sát taxonomy tới demo, kiểm thử và báo cáo.

SẢN PHẨM ĐÍCH

Một repository tái lập được, demo hỗ trợ kiểm duyệt ba phương thức, bộ nhãn có phiên bản, báo cáo thí nghiệm và phân tích giới hạn khoa học; không tuyên bố thay thế hệ thống kiểm duyệt thật.

MỤC LỤC

THÔNG TIN TÀI LIỆU 2
01 Tổng quan và bài toán 4
02 Phạm vi, giả định và giới hạn 4
03 Cơ sở chính sách: Meta và TikTok 5
04 Bộ nhãn kiểm duyệt MCST v1.0 6
05 Mô hình nhãn, ngữ cảnh và quyết định 7
06 Yêu cầu chức năng 8
07 Yêu cầu phi chức năng và an toàn 9
08 Kiến trúc hệ thống và luồng xử lý 10
09 Dữ liệu và chiến lược gán nhãn 11
10 Thiết kế mô hình và thực nghiệm 12
11 Thước đo, mục tiêu và kiểm thử 12
12 Thiết kế phần mềm và API mẫu 13
13 Kế hoạch triển khai 16 tuần 14
14 Rủi ro, đạo đức và phương án giảm thiểu 15
15 Sản phẩm bàn giao và tiêu chí nghiệm thu 15
16 Tài liệu tham khảo 16
17 Phụ lục: mẫu dữ liệu đầu ra 17

01 Tổng quan và bài toán

1.1. Bối cảnh

Nội dung do người dùng tạo trên mạng xã hội tồn tại dưới nhiều dạng: văn bản ngắn, văn bản đặt trên ảnh, lời nói, hành động và những tương tác giữa chúng trong video. Một bộ lọc chỉ dựa trên từ khóa hoặc chỉ trên hình ảnh dễ bỏ sót ngữ cảnh hoặc cảnh báo nhầm nội dung mang mục đích giáo dục, báo chí, phê phán.

Các bộ Tiêu chuẩn cộng đồng như Meta và TikTok có vùng giao nhau về loại tổn hại nhưng khác cách diễn giải, mức hạn chế phân phối và ngoại lệ. Đồ án đề xuất một cấu trúc nhãn trung gian có phiên bản để mô hình dự đoán tín hiệu rủi ro, còn lớp chính sách đưa ra hành động phù hợp.

1.2. Phát biểu bài toán

> **BÀI TOÁN CỐT LÕI**
>
> Cho đầu vào x thuộc một hay nhiều phương thức (T, I, V, A), xây dựng hệ thống f(x) trả về: **(i)** tập nhãn rủi ro, **(ii)** vị trí bằng chứng, **(iii)** ngữ cảnh/ngoại lệ, **(iv)** độ tin cậy và **(v)** hành động đề xuất. Việc gỡ hoặc hạn chế nội dung là quyết định của lớp chính sách và có thể cần người kiểm duyệt.

1.3. Mục tiêu nghiên cứu

- Chuẩn hóa bộ taxonomy gồm **16 nhóm cấp 1**, có ánh xạ đến chính sách Meta/TikTok và khả năng bổ sung nhãn con.
- Xây dựng baseline theo từng phương thức: phân loại văn bản tiếng Việt, ảnh/chữ trên ảnh, video kèm âm thanh.
- Thử nghiệm **late fusion** và ít nhất một chiến lược kết hợp đa phương thức, có phân tích trường hợp sai.
- Thiết kế pipeline gán nhãn, kiểm tra chất lượng dữ liệu, cơ chế giám sát con người và bản demo tra cứu kết quả.
- Đánh giá khả năng tổng quát, sai lệch theo ngôn ngữ/định dạng, mức độ hiệu chỉnh xác suất và chi phí thực thi.

1.4. Câu hỏi nghiên cứu

RQ1. Bộ nhãn hợp nhất có giảm bất đồng gán nhãn so với hướng dẫn tách riêng theo Meta/TikTok? **RQ2.** Kết hợp OCR, ASR và biểu diễn hình ảnh/video có cải thiện Macro-F1 so với baseline từng phương thức? **RQ3.** Phân tích ngữ cảnh và cơ chế “không chắc chắn duyệt thủ công” có giảm tỷ lệ cảnh báo nhầm?

02 Phạm vi, giả định và giới hạn

Phạm vi	Bao gồm trong đồ án	Ngoài phạm vi MVP
Đầu vào	Văn bản tiếng Việt, ảnh tĩnh, meme, video ngắn có âm thanh/lời nói	Livestream thời gian thực; chuỗi hội thoại riêng tư nhiều người
Phân loại	Tập nhãn rủi ro nhiều lớp, đa nhãn và bằng chứng liên quan	Khẳng định pháp lý, kết luận bản quyền tự động
Quyết định	Đề xuất ALLOW / RESTRICT / REMOVE / ESCALATE; xem xét ngoại lệ	Tự động gỡ/khóa tài khoản trên nền tảng thật
Ngôn ngữ	Tiếng Việt, một phần trộn tiếng Anh và tiếng lóng	Bảo đảm hiệu quả trên mọi ngôn ngữ
Giao diện	Demo upload nội dung, xem nhãn, thời điểm/đoạn bằng chứng	Hệ thống kiểm duyệt thương mại quy mô lớn

2.1. Phạm vi triển khai theo hai mức

MVP bắt buộc: 8 nhãn ưu tiên: C01 HATE, C02 HARASSMENT, C03 VIOLENCE, C04 GRAPHIC, C08 SEXUAL_CONTENT, C09 SELF_HARM, C11 FRAUD và C16 SPAM. Cho phép một số nhãn thiếu dữ liệu chỉ dừng ở mức phát hiện nguy cơ và chuyển duyệt, không yêu cầu độ chính xác ngang bằng các lớp có dữ liệu tốt.

Mở rộng: duy trì schema của đầy đủ 16 nhóm, bổ sung mô hình chuyên biệt cho 8 nhóm còn lại theo giấy phép, dữ liệu và thời gian cho phép; các nhóm đặc biệt nhạy cảm ưu tiên quy trình chuyển duyệt an toàn.

2.2. Giả định thiết kế

- Có quyền sử dụng hợp lệ đối với dữ liệu và tuân thủ điều kiện của từng bộ dữ liệu.
- Video thử nghiệm là video ngắn (gợi ý 60 giây), được lưu và xử lý trong môi trường thử nghiệm có kiểm soát.
- Không suy ra "không vi phạm" chỉ vì mô hình không gán nhãn; hệ thống có trạng thái thiếu bằng chứng/chưa xác định.
- Mọi chính sách đều phải lưu **nguồn và phiên bản**, do nội dung và cách thực thi có thể thay đổi.

03 Cơ sở chính sách: Meta và TikTok

3.1. Phân tích theo góc nhìn hệ thống

Khía cạnh	Meta	TikTok
Nhóm vấn đề	Cấu trúc chính sách rộng: bạo lực, an toàn, nội dung phản cảm, tính xác thực, sở hữu trí tuệ.	Nhóm Safety and Civility, Mental/Behavioral Health, Sensitive Themes, Integrity, Regulated Goods và Privacy.
Hình thức nội dung	Quy tắc áp dụng cho bài viết, hình ảnh, video và nội dung có AI; một số trường hợp cần ngữ cảnh.	Quy tắc áp dụng cho video, bình luận, ảnh, LIVE; nhiều trường hợp gắn với phân phối For You và tuổi.
Can thiệp	Xóa, cảnh báo, giới hạn truy cập/tuổi hoặc phân phối tùy quy tắc và ngữ cảnh.	Không cho phép, giới hạn tuổi hoặc không đủ điều kiện xuất hiện trong For You; có cơ chế khiếu nại.
Khả năng áp dụng ML	Thuận lợi để xác định nhóm tổn hại và nhãn con đa cấp.	Thuận lợi để thiết kế hành động có điều kiện và ví dụ gán nhãn theo ngữ cảnh.

NGUYÊN TẮC ÁNH XẠ

Ánh xạ bên dưới phản ánh sự tương đồng **về nội dung quy tắc**, không phải 1-1 hoặc một mô hình dự báo được quyết định thật của nền tảng. Cần ghi rõ nguồn, ngày truy cập và phiên bản khi tái lập kết quả. [1][2]

3.2. Các trường hợp phải đánh giá theo ngữ cảnh

- **Ghi nhận bạo lực vs. kích động bạo lực:** hình ảnh hiện trường có thể nhạy cảm nhưng không cổ súy hành vi.
- **Thảo luận sức khỏe vs. khuyến khích tự hại:** lời chia sẻ tìm hỗ trợ không nên bị đồng nhất với cổ súy.
- **Giáo dục / nghệ thuật vs. nội dung tình dục:** hình thức hiển thị và mục đích sử dụng cùng quan trọng.
- **Meme, châm biếm và trích dẫn:** chữ và ảnh có thể mang nghĩa đối lập khi tách riêng.
- **AI-generated / thông tin sai lệch:** phát hiện tín hiệu phải tách khỏi xác minh nguồn và sự kiện.

04 Bộ nhãn kiểm duyệt MCST v1.0

Mỗi nội dung có thể mang **nhiều nhãn đồng thời**. Nhãn cấp 1 phản ánh loại rủi ro; nhãn con xác định dạng hành vi cụ thể; ngữ cảnh và hành động được lưu độc lập. Ký hiệu phương thức: T = văn bản, I = ảnh, V = video (bao gồm âm thanh trong video).

4.1. Ma trận ánh xạ 16 nhãn

MCST v1.0	Meta (quy tắc gần nhất)	TikTok (quy tắc gần nhất)	Mode
C01 • HATE	Hateful Conduct / Hate Speech	Hate Speech & Hateful Behavior	T,I,V
C02 • HARASSMENT	Bullying and Harassment	Harassment and Bullying	T,I,V
C03 • VIOLENCE	Violence and Incitement	Violent and Criminal Behavior	T,I,V
C04 • GRAPHIC	Violent and Graphic Content	Shocking and Graphic Content	I,V
C05 • CRIME	Dangerous Organizations / Coordinating Harm / Human Exploitation	Violent & Hateful Actors / Trafficking	T,I,V
C06 • CHILD_SAFETY	Child Sexual Exploitation, Abuse and Nudity	Youth Sexual and Physical Abuse	T,I,V
C07 • SEXUAL_ABUSE	Adult Sexual Exploitation	Adult Sexual Abuse	T,I,V
C08 • SEXUAL_CONTENT	Adult Nudity / Sexual Solicitation	Body Exposure and Sexualized Behaviors	T,I,V
C09 • SELF_HARM	Suicide, Self-Injury and Eating Disorders	Suicide & Self-Harm / Disordered Eating	T,I,V
C10 • DANGEROUS_ACTS	Violence/animal harm or related safety policies	Dangerous Activity & Challenges / Animal Abuse	I,V
C11 • FRAUD	Fraud, Scams and Deceptive Practices	Frauds and Scams	T,I,V
C12 • REGULATED	Restricted Goods and Services	Regulated Goods and Services	T,I,V
C13 • PRIVACY	Privacy Violations	Personal Information	T,I,V
C14 • MISINFO	Misinformation	Misinformation / Civic & Election Integrity	T,I,V
C15 • AI_MEDIA	AI disclosure + related harm policies	Edited Media & AI-Generated Content	I,V
C16 • SPAM	Spam / Inauthentic Behavior	Deceptive Behaviors & Fake Engagement	T,I,V

Ghi chú: C05, C09 và C10 là các nhóm tổng hợp, yêu cầu nhãn con để tách những hành vi không đồng nhất. C15 là tín hiệu phân loại/kiểm tra, không mặc định là vi phạm. C14 thường cần hệ thống kiểm chứng bên ngoài. [1][2]

4.2. Các nhãn con minh họa

Nhãn cấp 1	Ví dụ nhãn con	Quy tắc gán
C03_VIOLENCE	threat / incitement / glorification	Phân biệt phát ngôn đe dọa với đưa tin hoặc trích dẫn.
C04_GRAPHIC	injury / accident / gore	Ghi ngữ cảnh báo chí, cảnh báo, giáo dục; không đồng nhất với C03.
C09_SELF_HARM	promotion / help_seeking / recovery	help_seeking và recovery là ngữ cảnh cần hỗ trợ, không tự thành vi phạm.
C11_FRAUD	impersonation / financial_scam / phishing	Có thể cần xác minh danh tính/link ngoài nội dung.
C15_AI_MEDIA	synthetic / impersonation_risk / unlabeled	Synthetic-only không đủ để kết luận xóa.

05 Mô hình nhãn, ngữ cảnh và quyết định

5.1. Trường đầu ra tối thiểu

Trường	Kiểu	Ý nghĩa / ràng buộc
content_id	string	Định danh nội dung; không chứa dữ liệu cá nhân.
modality	enum	text / image / video
policy_version	string	Phiên bản taxonomy và bản đối chiếu chính sách.
labels	array	Danh sách mã nhãn đa nhãn, có score và sublabel khi sẵn có.
context	array	news / education / documentary / satire / counterspeech / self_report / unclear...
evidence	array	text_span / image_region / video_timestamp / audio_segment.
recommended_action	enum	ALLOW / RESTRICT / REMOVE / ESCALATE.
review_required	boolean	Bắt buộc cho nội dung nhạy cảm, thiếu bằng chứng hoặc ngưỡng không chắc chắn.

5.2. Nguyên tắc đề xuất xử lý

Hành động	Khi nào gợi ý	Lưu ý
ALLOW	Không tìm thấy tín hiệu đáng tin; ngữ cảnh hợp lệ được xác nhận.	Không đồng nghĩa đã chứng minh “an toàn tuyệt đối”.
RESTRICT	Nội dung nhạy cảm phù hợp cho cảnh báo/giới hạn tuổi/giảm đề xuất.	Chế độ xử lý phụ thuộc nền tảng và quy định.
REMOVE	Quy tắc rõ ràng, bằng chứng đủ mạnh, không có ngoại lệ áp dụng.	MVP chỉ gợi ý; không tự gỡ nội dung thật.
ESCALATE	Độ tin cậy thấp, nhãn mâu thuẫn, nhạy cảm cao, có nguy cơ khẩn cấp.	Gửi hàng đợi duyệt; thời gian/độ ưu tiên theo rủi ro.

BẤT BIẾN THIẾT KẾ

Score của mô hình phán quyết vi phạm. Kết quả gán nhãn là bằng chứng hỗ trợ; lớp Policy Engine xét nhãn, ngữ cảnh, ngoại lệ, độ chắc chắn và quy tắc theo phiên bản trước khi gợi ý hành động.

06 Yêu cầu chức năng

Mức ưu tiên: **M** = Must-have (MVP); **S** = Should-have; **C** = Could-have. Các yêu cầu được kiểm thử bằng ví dụ đầu vào và đầu ra có cấu trúc.

Mã	Ưu tiên	Yêu cầu
FR-01	M	Tiếp nhận văn bản tiếng Việt (UTF-8); kiểm tra độ dài và rỗng.
FR-02	M	Tiếp nhận ảnh JPG/PNG/WEBP và trích xuất chữ OCR.
FR-03	M	Tiếp nhận video MP4 ngắn; trích khung hình và audio.
FR-04	M	Chạy ASR tiếng Việt trên audio trong video, lưu mốc thời gian.
FR-05	M	Dự đoán nhiều nhãn kèm điểm tin cậy cho từng phương thức.
FR-06	M	Kết hợp đầu ra encoder đa phương thức tại tầng fusion.
FR-07	M	Trả bằng chứng tương ứng: span chữ, timestamp, vùng ảnh khi hỗ trợ.
FR-08	M	Ghi ngữ cảnh thiếu bằng chứng/ngoại lệ và cho phép ESCALATE.
FR-09	M	Áp dụng Policy Engine theo phiên bản taxonomy.
FR-10	M	Giao diện tải nội dung, xem nhãn, score, bằng chứng và hành động.
FR-11	M	Xuất báo cáo thử nghiệm, confusion matrix và chỉ số theo nhãn.
FR-12	S	Quản lý hàng đợi kiểm duyệt và ghi nhận quyết định của người duyệt.
FR-13	S	Lưu audit log: phiên bản model, policy, timestamp và reviewer.
FR-14	S	API cho text/image/video với validation và lỗi có cấu trúc.
FR-15	C	So sánh quyết định MCST với cấu hình ánh xạ Meta/TikTok.
FR-16	C	Đề xuất mẫu cần gán nhãn bằng active learning.

6.1. Vai trò người dùng

Researcher: nhập dữ liệu, huấn luyện, xem đánh giá. **Reviewer:** xem bằng chứng và chốt trường hợp ESCALATE. **Admin:** cấu hình phiên bản chính sách và quản lý quyền truy cập. MVP có thể gom Researcher/Admin trong giao diện demo, nhưng dữ liệu kiểm duyệt nhạy cảm phải được phân quyền.

07 Yêu cầu phi chức năng và an toàn

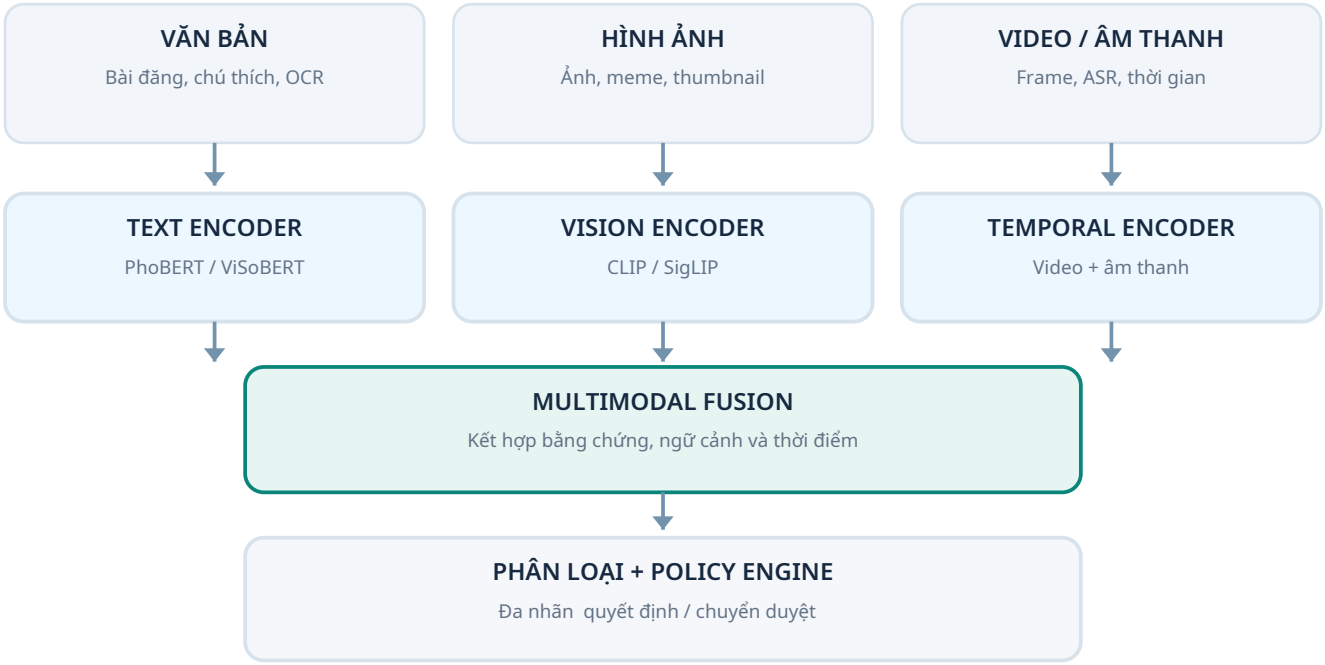
Mã	Nhóm	Đặc tả / tiêu chí kiểm tra
NFR-01	Tái lập	Mỗi lần train lưu seed, config, phiên bản dữ liệu, split và checkpoint.
NFR-02	Chất lượng	Báo cáo Precision, Recall, F1 cho từng nhãn; ưu tiên Macro-F1 và false positives.
NFR-03	Truy xuất	Kết quả có ID, phiên bản mô hình, thời gian xử lý và bằng chứng khi khả thi.
NFR-04	Bảo mật	Validation upload; chỉ chấp nhận định dạng cho phép; giới hạn dung lượng và phân quyền.
NFR-05	Riêng tư	Ẩn danh ID, xóa metadata không cần thiết; đặt chính sách lưu/xóa dữ liệu.
NFR-06	An toàn	Không tự lưu, nhân bản, hoặc huấn luyện trên nội dung bất hợp pháp/khai thác trẻ em.
NFR-07	Độ tin cậy	Đối với lỗi OCR/ASR hoặc dữ liệu hỏng, trả lỗi/không chắc chắn có giải thích.
NFR-08	Công bằng	Đánh giá bổ sung theo phương ngữ, viết tắt, tiếng lóng và nhóm ngữ cảnh.
NFR-09	Hiệu năng	Báo cáo latency p50/p95, GPU RAM, thông lượng trên cấu hình test được công bố.
NFR-10	Mở rộng	Thêm nhãn/policy_version mà không bắt buộc thiết kế lại API.

7.1. Điều kiện bảo vệ dữ liệu

- Ưu tiên dữ liệu được cấp phép công khai hoặc đã có quyền và sự đồng ý; tránh lấy dữ liệu từ tài khoản riêng tư.
- Đối với nội dung có người thật, thông tin cá nhân và giọng nói: giảm lưu trữ, kiểm soát truy cập, che/mã hóa khi thích hợp.
- Không tái phân phối dữ liệu gốc nếu giấy phép không cho phép; ghi nguồn, điều kiện sử dụng và trạng thái quyền.
- Những trường hợp có nguy cơ nghiêm trọng được chuyển đến quy trình an toàn phù hợp; không yêu cầu người gán nhãn xem nội dung xâm hại trẻ em.

08 Kiến trúc hệ thống và luồng xử lý

8.1. Kiến trúc tham chiếu



Hình 1. Pipeline đề xuất: các mô hình chuyên biệt trích xuất tín hiệu fusion học sự bổ sung/mâu thuẫn policy engine đưa ra khuyến nghị.

8.2. Pipeline theo phương thức

Nguồn	Tiền xử lý	Encoder / mô-đun
Văn bản	Chuẩn Unicode, chia đoạn dài, giữ dấu và tiếng lóng có ý nghĩa.	TF-IDF + Linear SVM (baseline); PhoBERT/ViSoBERT.
Hình ảnh	Resize, kiểm tra chất lượng, OCR, ghép chuỗi chữ vào nội dung.	CLIP/SigLIP hoặc vision backbone + text branch.
Video	Lấy frame theo chu kỳ và các thời điểm biến động; ASR; đồng bộ timestamps.	Temporal pooling / video encoder; visual + OCR + ASR.
Kết hợp	Đồng bộ đầu ra, dùng missing-modality mask, ước lượng confidence.	Late fusion (baseline) attention/gated fusion (mở rộng).

8.3. Thiết kế quy trình xử lý



Có thể triển khai bằng Python + PyTorch/Transformers, FastAPI và web UI thử nghiệm. Đây là lựa chọn công nghệ khuyến nghị, không ràng buộc; ưu tiên các thư viện có giấy phép và phần cứng phù hợp.

09 Dữ liệu và chiến lược gán nhãn

9.1. Nguồn dữ liệu và mục đích

Nguồn	Vai trò	Hạn chế cần kiểm tra
VTSNLP Vietnamese Curated Dataset [3]	Kho văn bản tiếng Việt cho lấy mẫu, phân tích miền, tiền huấn luyện phụ trợ.	12.169.131 bản ghi; có text/id/domain, không có nhãn vi phạm.
ViHSD [4]	Baseline text cho CLEAN/OFFENSIVE/HATE (~33K bình luận).	Không suy ra trực tiếp 16 nhãn MCST; kiểm tra license theo bản sử dụng.
ViSoLex VN-HSD [5]	Dữ liệu gộp phục vụ khảo sát hate speech.	Nhãn đã ánh xạ từ nguồn khác, cần kiểm tra rò rỉ nguồn.
Dữ liệu ảnh/video được phép dùng	Bổ sung các nhóm thị giác, meme và video có ngữ cảnh.	Cần chứng minh quyền sử dụng, bảo mật và tính đại diện.
Bộ dữ liệu đồ án tự gán nhãn	Ground truth kiểm chứng MCST theo quy tắc nghiên cứu.	Tốn chi phí gán nhãn; chú trọng bảo vệ người gán nhãn.

9.2. Kế hoạch lấy mẫu và tách tập

Khảo sát taxonomy: 900 mẫu, gồm 300 text + 300 image + 300 video, ưu tiên sự đa dạng và các trường hợp ranh giới chính sách. **Huấn luyện MVP:** mục tiêu 3.000–6.000 mẫu có nhãn được kiểm tra; bổ sung dữ liệu công khai phù hợp và tăng cường có kiểm soát. Các con số là mục tiêu, không phải số dữ liệu đã thu thập.

Chia train/validation/test: gợi ý 70/15/15 theo nhóm nguồn và nhóm nội dung, giữ nguyên tất cả frame/video cắt từ cùng tài sản trong một split. Test set có nhãn do người đánh giá xác minh; không sử dụng nó để chọn ngưỡng.

9.3. Hướng dẫn gán nhãn

- **Bước 1:** xem đủ ngữ cảnh và chỉ ra bằng chứng trực tiếp.
- **Bước 2:** gán tất cả nhãn cấp 1 thực sự xuất hiện; không suy diễn động cơ từ một tín hiệu đơn lẻ.
- **Bước 3:** xác định nhãn con và ngữ cảnh (giáo dục, báo chí, trích dẫn, phê phán, không rõ...).
- **Bước 4:** tách nhãn nội dung khỏi xử lý chính sách; đánh dấu bất định nếu thiếu dữ liệu.
- **Bước 5:** hai người gán độc lập; bất đồng do người thứ ba phân xử; lưu rationale ngắn gọn.

Chỉ số chất lượng: Krippendorff's alpha hoặc Cohen's kappa cho tập nhãn thích hợp, tỷ lệ bất đồng, thời gian gán nhãn, tỷ lệ "không đủ ngữ cảnh". Mục tiêu khảo sát **α ≥ 0,67** để cân nhắc sử dụng nghiên cứu; **α ≥ 0,80** nếu có thể đạt sau tinh chỉnh hướng dẫn (không áp dụng máy móc cho mọi nhãn hiếm).

10 Thiết kế mô hình và thực nghiệm

10.1. Cấu hình baseline và phương án chính

Mã	Mô hình / thí nghiệm	Mục tiêu so sánh
E1	TF-IDF + Linear SVM (text); encoder ảnh đóng băng + linear head.	Baseline đơn giản, chi phí thấp.
E2	Fine-tune PhoBERT/ViSoBERT trên text; ảnh + OCR fusion.	Lợi ích encoder tiếng Việt và chữ trên ảnh.
E3	Video frame-only; ASR-only; frame+ASR.	Đóng góp riêng của hình ảnh chuyển động và lời nói.
E4	Late fusion (text, image, video/audio).	So sánh với từng phương thức và hiệu quả khi thiếu modality.
E5	Gated/attention fusion hoặc VLM kiểm chứng một tập nhỏ.	Phân tích mức cải thiện so với baseline có kiểm soát.

10.2. Các thí nghiệm ablation bắt buộc

- Text-only vs. text+OCR; image-only vs. image+caption.
- Video frame-only vs. ASR-only vs. kết hợp có trục thời gian.
- Có/không dùng nhãn ngữ cảnh và lớp ESCALATE.
- Không cân bằng lớp vs. weighted loss/focal loss; threshold 0,5 vs. threshold hiệu chỉnh trên validation.
- Đánh giá trên mẫu nhiễu: lỗi OCR, ASR, tiếng lóng, mỉa mai, video không lời và thiếu modality.

10.3. Kiểm soát thực nghiệm

Cố định seed và split cho từng phép so sánh; lưu mã nguồn, config và mã commit; kiểm tra trùng lặp theo văn bản/ảnh/video; không trộn phiên bản cùng một meme/video giữa train và test. Nếu sử dụng LLM/VLM làm tham chiếu, phải cố định prompt và phiên bản model; không coi nhãn sinh tự động là ground truth.

11 Thước đo, mục tiêu và kiểm thử

Nhóm	Thước đo bắt buộc	Tiêu chí nghiệm thu đề xuất
Phân loại	Macro-F1, Micro-F1, PR-AUC, Precision/Recall từng nhãn, confusion matrix.	Báo cáo đầy đủ trên test độc lập; cải thiện 3 điểm % Macro-F1 so với baseline phù hợp là mục tiêu kỳ vọng, không cam kết.
An toàn	False-positive rate ở mẫu hợp lệ; false-negative rate nhóm nguy cơ; recall@precision constraint.	Có ma trận lỗi và phân tích ít nhất 30 ca sai đại diện.
Bất định	ECE/Brier score (nếu xác suất); coverage–risk theo ngưỡng ESCALATE.	Thiết lập threshold trên validation; báo cáo tỉ lệ chuyển duyệt.
Gán nhãn	Inter-annotator agreement, ambiguity/coverage, thời gian gán nhãn.	Báo cáo ít nhất trên 900 mẫu pilot và hướng dẫn đã hiệu chỉnh.
Vận hành	Latency p50/p95, RAM/VRAM, tỉ lệ lỗi upload, thời gian xử lý video.	Có benchmark và cấu hình phần cứng ghi rõ; không đặt SLA cứng khi chưa có GPU.

11.1. Các kịch bản kiểm thử chấp nhận

ID	Đầu vào	Đầu ra / điều kiện đạt
AT-01	Bình luận tiếng Việt đe dọa trực tiếp.	Có nhãn C03 và span văn bản liên quan; có score.
AT-02	Meme có chữ công kích nhóm người được bảo vệ.	OCR hoạt động; kết quả dùng cả ảnh và chữ.
AT-03	Video có lời nói và hành động khác nhau.	Kết quả có timestamp và đánh giá kết hợp hai nhánh.
AT-04	Đoạn tin tức ghi nhận sự cố gây sốc.	Có ngữ cảnh news/documentary; không mặc định kích động bạo lực.
AT-05	Dữ liệu thiếu âm thanh, lỗi OCR hoặc ảnh/video hỏng.	Không treo hệ thống; trả lỗi cụ thể hoặc ESCALATE.
AT-06	Nội dung ranh giới/chính sách chưa rõ.	Giữ trạng thái bất định và chuyển duyệt; log đầy đủ.

12 Thiết kế phần mềm và API mẫu

12.1. Các thành phần

- **Ingestion service:** kiểm tra loại tệp, dung lượng, tạo content_id và chuẩn hóa metadata.
- **Inference service:** điều phối OCR/ASR, encoders, fusion, batch và tài nguyên GPU.
- **Policy engine:** ánh xạ label điều kiện chính sách recommended_action theo phiên bản.
- **Reviewer UI:** kết quả và bằng chứng; thao tác ghi đè có lưu lý do.
- **Experiment dashboard:** hiển thị metric, phân bố nhãn, mẫu lỗi và versioning.

12.2. Hợp đồng API đề xuất

Method / endpoint	Ý nghĩa	Kết quả chính
POST /v1/moderate/text	Phân loại văn bản JSON.	content_id, labels, context, decision.
POST /v1/moderate/image	Upload ảnh và mô tả tùy chọn.	labels, OCR evidence, decision.
POST /v1/moderate/video	Upload video; job có thể bất đồng bộ theo yêu cầu client.	job_id, status; khi hoàn tất trả timestamps.
GET /v1/jobs/{id}	Truy vấn tiến độ video.	queued / running / done / failed.
POST /v1/reviews/{id}	Lưu xác nhận/điều chỉnh của reviewer.	reviewed_labels, action, audit_id.

API này là đặc tả mục tiêu, chưa phải API đã được triển khai. Định dạng lỗi có mã và thông điệp rõ ràng; URL tệp và metadata nhạy cảm không được công khai trong log.

12.3. Bố cục repository khuyến nghị

- **configs/** taxonomy, thresholds, policy mapping, experiments
- **data/** scripts tạo manifest; không commit dữ liệu gốc nhạy cảm
- **src/** preprocessing, models, fusion, policy, evaluation, api
- **annotation/** labeling guide, QC, schema, examples an toàn
- **tests/** unit, integration, acceptance; **reports/** metrics và artifacts

13 Kế hoạch triển khai 16 tuần

Giai đoạn	Tuần	Công việc chính	Mốc bàn giao
P1 — Khảo sát	1–3	Đối chiếu chính sách, xác định MCST; viết guideline; lấy mẫu pilot.	Taxonomy v1; 900 mẫu khảo sát; báo cáo bất đồng.
P2 — Dữ liệu	4–6	Chốt nguồn, quyền dùng, pipeline OCR/ASR; QC, tạo split; baseline text.	Manifest, annotation guide v2; text baseline.
P3 — Mô hình	7–10	Huấn luyện image/video encoder; đánh giá theo phương thức; late fusion.	Model checkpoints và bảng ablation v1.
P4 — Hệ thống	11–13	Xây API, UI, policy engine, review flow; tích hợp end-to-end.	Demo có chức năng theo FR-M; test integration.
P5 — Đánh giá	14–15	Chạy test độc lập, hiệu chỉnh ngưỡng, phân tích lỗi, kiểm tra riêng tư.	Báo cáo metric, robustness, error analysis.
P6 — Tổng kết	16	Đóng gói, viết báo cáo, chuẩn bị demo và slide.	Repo + tài liệu + video demo + báo cáo cuối.

13.1. Phụ thuộc và ưu tiên

Hướng dẫn gán nhãn phải được thống nhất **trước khi** tập trung huấn luyện. Với hạn chế GPU, ưu tiên encoder đã được tiền huấn luyện và đóng băng backbone trong vòng thử nghiệm đầu, sau đó chỉ fine-tune các nhánh có đủ nhãn.

13.2. Quản lý thay đổi

Mỗi thay đổi taxonomy phải tăng policy_version, nêu lý do, ảnh hưởng tới tập nhãn cũ và chỉ số so sánh. Nếu thay đổi định nghĩa một nhãn, cần relabel tập đánh giá liên quan hoặc công bố không thể so sánh trực tiếp giữa các phiên bản.

14 Rủi ro, đạo đức và phương án giảm thiểu

Rủi ro	Hệ quả	Biện pháp
Thiếu dữ liệu nhãn hiếm	Macro-F1 thấp, bỏ sót nhóm quan trọng.	Giới hạn MVP, active learning, bổ sung thủ công hợp pháp; ESCALATE cho lớp chưa đủ bằng chứng.
Nhãn không nhất quán	Model học quy tắc sai.	Guideline có ví dụ ranh giới; 2 annotator + adjudication; audit theo phiên bản.
Mâu thuẫn chính sách	Gợi ý xử lý thiếu nhất quán.	Tách detection/context/decision; lưu source và version.
Rò rỉ train–test	Kết quả đánh giá ảo.	Group split theo nguồn, video gốc và hash nội dung; đánh giá ngoài miền.
Thông tin cá nhân	Xâm phạm riêng tư và quyền người dùng.	Minimize data, che PII, phân quyền và thời hạn xóa.
Nội dung nhạy cảm	Rủi ro cho người gán nhãn và người dùng.	Không lưu nội dung bất hợp pháp; cảnh báo, truy cập giới hạn; quy trình tiếp nhận/báo cáo phù hợp.
Thiên lệch tiếng Việt	Cảnh báo nhầm phương ngữ/tiếng lóng.	Bộ test phân tầng, phân tích sai theo nhóm ngôn ngữ và ngữ cảnh.
Trôi chính sách/model	Dự đoán không còn phù hợp.	Versioning, bộ regression test, lịch đánh giá lại khi chính sách đổi.
Nguồn lực GPU	Không hoàn thành tất cả 16 nhãn.	Khóa 8 nhãn MVP, cache embeddings, ưu tiên late fusion trước.

NGUYÊN TẮC ĐẠO ĐỨC

Hệ thống là công cụ **hỗ trợ** quyết định. Tránh đánh đồng đặc điểm cá nhân/nhóm xã hội với vi phạm; bảo vệ tự do biểu đạt, khả năng phản hồi của người bị tác động và tính minh bạch của bằng chứng. Nội dung nghiêm trọng hoặc trái pháp luật cần xử lý bằng quy trình an toàn phù hợp, không dùng làm dữ liệu huấn luyện tùy tiện.

15 Sản phẩm bàn giao và tiêu chí nghiệm thu

15.1. Deliverables

Mã	Hạng mục	Điều kiện bàn giao
D01	Taxonomy MCST v1.0 và bảng ánh xạ	16 nhãn cấp 1, định nghĩa/nhãn con chính, ngoại lệ và policy sources.
D02	Annotation guideline và dữ liệu mẫu	Biểu mẫu, QC, pilot 900 mẫu và dữ liệu huấn luyện có nguồn hợp lệ.
D03	Các baseline và multimodal model	Checkpoint/config và scripts tái lập; ít nhất text, image, video branch.
D04	Policy Engine và demo	Nhập text/ảnh/video nhãn, score, evidence, action + ESCALATE.
D05	Bộ đánh giá	Metric từng nhãn/phương thức, ablation, phân tích sai và fairness slices.
D06	Báo cáo đồ án và repository	Sơ đồ kiến trúc, SRS, giới hạn, ethics, cách chạy và test.

15.2. Các cổng kiểm tra (gates)

- **Gate A — Đúng bài toán:** dữ liệu phải có nhãn kiểm duyệt MCST hoặc nhãn nguồn được ánh xạ, không dùng nhãn domain của VTSNLP làm ground truth.

- **Gate B — Đúng quy trình:** có test độc lập, không rò rỉ, báo cáo benchmark và seed/config.
- **Gate C — Đủ MVP:** demo chạy được cho text, image, video và trả lời theo schema thống nhất.
- **Gate D — Có căn cứ:** kết luận dựa trên bảng so sánh và ablation, không quảng cáo khả năng kiểm duyệt toàn diện khi thiếu dữ liệu.
- **Gate E — An toàn:** có chính sách xử lý dữ liệu nhạy cảm, quyền truy cập và cơ chế chuyển duyệt.

> **TIÊU CHÍ THÀNH CÔNG**
>
> Đồ án được xem là đạt mục tiêu nghiên cứu khi có **taxonomy rõ ràng, dữ liệu đánh giá đáng tin, hệ thống demo ba phương thức, mô hình baseline và multimodal, báo cáo định lượng tái lập được**. Không yêu cầu "đạt X% accuracy trên 16 nhãn" nếu chưa có tập test đủ lớn/đại diện.

16 Tài liệu tham khảo

[1] Meta Transparency Center — Community Standards
https://transparency.meta.com/policies/community-standards/
Đối chiếu các nhóm chính sách và ngoại lệ theo ngữ cảnh.

[2] TikTok — Community Guidelines
https://www.tiktok.com/community-guidelines
Các quy tắc an toàn, tính xác thực, nội dung nhạy cảm, cơ chế hạn chế/For You.

[3] VTSNLP — vietnamese_curated_dataset
https://huggingface.co/datasets/VTSNLP/vietnamese_curated_dataset
Thẻ dữ liệu; text/id/domain; 12.169.131 mẫu train.

[4] UIT-NLP — ViHSD
https://huggingface.co/datasets/uitnlp/vihsd
Bộ dữ liệu phát hiện hate speech tiếng Việt (~33K bình luận).

[5] ViSoLex — VN-HSD
https://huggingface.co/datasets/visolex/VN-HSD
Bộ dữ liệu hợp nhất phục vụ các baseline hate speech.

[6] PhoBERT — Pre-trained language models for Vietnamese
https://aclanthology.org/2020.findings-emnlp.92/
Nguồn tham khảo backbone NLP tiếng Việt.

[7] ViSoBERT — Vietnamese Social Media Language Model
https://aclanthology.org/2023.emnlp-main.315/
Mô hình ngôn ngữ tiền huấn luyện cho dữ liệu mạng xã hội.

Lưu ý về nguồn: các chính sách nền tảng được cập nhật theo thời gian, có thể khác nhau theo khu vực và tính năng. Danh mục/tên nhóm trong tài liệu này được dùng cho đối chiếu nghiên cứu tại ngày biên soạn; khi triển khai phải xác nhận lại phiên bản đang có hiệu lực và lưu bản snapshot được phép sử dụng.

17 Phụ lục: mẫu dữ liệu đầu ra

Ví dụ minh họa giả lập dùng cho kiểm thử nội bộ, không phải kết quả từ một mô hình đã huấn luyện.

Trường / giá trị ví dụ
{
"content_id": "demo_001",
"modality": "video",
"language": "vi",
"policy_version": "MCST-1.0",
"labels": [
{"code": "C03_VIOLENCE", "score": 0.83,
"sub_label": "threat"}
],
"context": ["unclear"],
"evidence": [
{"source": "asr", "start_sec": 2.1,
"end_sec": 5.4, "text_span": "..."}
],
"recommended_action": "ESCALATE",
"review_required": true
}

Danh sách tài liệu bổ trợ nên bổ sung trong repository

- **docs/policy_mapping.md** — ánh xạ policy gốc MCST, ngày truy cập và ngoại lệ.
- **annotation/guideline_vi.md** — định nghĩa, phản ví dụ, các trường hợp bất đồng.
- **configs/taxonomy_v1.yaml** — bộ nhãn máy đọc được và bảng ngưỡng.
- **reports/model_card.md** — dữ liệu sử dụng, thiên lệch, hiệu quả và giới hạn.
- **reports/data_card.md** — nguồn, giấy phép, phạm vi và cách bảo vệ dữ liệu.

HẾT TÀI LIỆU